

TUGAS KELOMPOK PERTEMUAN 12
DATA MINING AND INFORMATION RETRIEVAL
TOOLS KNIME



Disusun oleh:

Rama Pramudya Wibisana	2022320019
Lidiani Gari	2022320066

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS INFORMATIKA
UNIVERSITAS BINA INSANI
BEKASI
2024

KNIME (/naim/), Konstanz Information Miner adalah platform analisis, pelaporan, dan integrasi data yang termasuk perangkat lunak bebas dan sumber terbuka . KNIME menyatukan berbagai komponen dalam bidang pembelajaran mesin dan penggalian data dengan konsep alur data yang modular. Antarmuka pengguna grafis dan penggunaan JDBC memungkinkan pembentukan simpul yang memadukan berbagai sumber data, termasuk tahap pre-processing (ETL: Extract, Transform, Load), tahap pemodelan, analisis data dan visualisasi tanpa atau dengan pemrograman. KNIME sering disebut sebagai alternatif SAS.

Kami akan melakukan contoh clustering K-Means menggunakan tools KNIME dengan menggunakan dataset jumlah Kabupaten/Kota yang mencapai eliminasi Malaria 2018-2020.


Sumber Dataset : <https://www.bps.go.id/id/statistics-table/2/MTc2NCMy/jumlah-kabupaten-kota-yang-mencapai-eliminasi-malaria.html>

Dataset:


Provinsi	2018	2019	2020
ACEH	19	21	21
SUMATERA UTARA	21	21	21
SUMATERA BARAT	16	17	17
RIAU	10	10	10
JAMBI	5	7	7
SUMATERA SELATAN	8	8	9
BENGKULU	3	3	4
LAMPUNG	10	11	11
KEP. BANGKA BELITUNG	5	6	6
KEP. RIAU	3	3	3
DKI JAKARTA	6	6	6
JAWA BARAT	23	23	25
JAWA TENGAH	30	33	33
DI YOGYAKARTA	3	4	4
JAWA TIMUR	38	38	38
BANTEN	6	6	6
BALI	9	9	9

NUSA TENGGARA BARAT	3	3	3
NUSA TENGGARA TIMUR	0	0	3
KALIMANTAN BARAT	3	3	4
KALIMANTAN TENGAH	9	10	11
KALIMANTAN SELATAN	7	7	7
KALIMANTAN TIMUR	3	3	3
KALIMANTAN UTARA	1	1	3
SULAWESI UTARA	6	6	8
SULAWESI TENGAH	4	5	6
SULAWESI SELATAN	19	20	21
SULAWESI TENGGARA	9	9	11
GORONTALO	2	2	2
SULAWESI BARAT	3	5	5
MALUKU	0	0	0
MALUKU UTARA	0	0	1
PAPUA BARAT	0	0	0
PAPUA	0	0	0


Langkah pertama kita perlu membuat workflow baru




Kemudian tambahkan node Excel Reader dikarenakan disini akan menggunakan data excel



Double click pada node Excel Reader, lalu pilih dataset yang akan diolah, kemudian click apply



Selanjutnya lakukan execute node.




Tambahkan node Missing Value, node ini dapat menangani nilai-nilai yang hilang, baik dengan menghapus baris, mengisi nilai, atau metode lainnya, lalu lakukan execut.

A screenshot of the KNIME Analytics Platform interface. The workflow consists of two nodes: 'Excel Reader' and 'Missing Value'. The 'Excel Reader' node is connected to the 'Missing Value' node. The 'Missing Value' node has a question mark icon and a comment field. The interface shows a table with 34 rows and 4 columns. The table data is as follows:

#	RowID	Provinsi	2018 Number (Integer)	2019 Number (Integer)	2020 Number (Integer)
1	Row0	ACEH	19	21	21
2	Row1	SUMATERA UTARA	21	21	21
3	Row2	SUMATERA BARAT	16	17	17
4	Row3	RIAU	10	10	10
5	Row4	JAMBI	5	7	7

Tambahkan node Normalizer, normalisasi data sangat penting sebelum melakukan k-means clustering. Gunakan node ini untuk menstandarkan data (misalnya, mengubah data menjadi distribusi dengan rata-rata 0 dan deviasi standar 1) agar semua fitur memiliki skala yang sama.



Setelah node Normalizer dilakukan execute maka didapat data yang sudah ternormalisasi


Normalized table (Table)						
Rows: 34 Columns: 4						
	#	RowID	Provinsi String	2018 Number (double)	2019 Number (double)	2020 Number (double)
☐	1	Row0	ACEH	0.5	0.553	0.553
☐	2	Row1	SUMATERA UTARA	0.553	0.553	0.553
☐	3	Row2	SUMATERA BARAT	0.421	0.447	0.447
☐	4	Row3	RIAU	0.263	0.263	0.263
☐	5	Row4	JAMBI	0.132	0.184	0.184
☐	6	Row5	SUMATERA SELAT...	0.211	0.211	0.237
☐	7	Row6	BENGKULU	0.079	0.079	0.105
☐	8	Row7	LAMPUNG	0.263	0.289	0.289
☐	9	Row8	KEP. BANGKA BELI...	0.132	0.158	0.158
☐	10	Row9	KEP. RIAU	0.079	0.079	0.079
☐	11	Row...	DKI JAKARTA	0.158	0.158	0.158
☐	12	Row...	JAWA BARAT	0.605	0.605	0.658
☐	13	Row...	JAWA TENGAH	0.789	0.868	0.868
☐	14	Row...	DI YOGYAKARTA	0.079	0.105	0.105
☐	15	Row...	JAWA TIMUR	1	1	1
☐	16	Row...	BANTEN	0.158	0.158	0.158
☐	17	Row...	BALI	0.237	0.237	0.237
☐	18	Row...	NUSA TENGGARA	0.079	0.079	0.079

Kemudian tambahkan node K-Means untuk melakukan proses clustering K-Means, kemudian akan didapatkan clusternya, disini dibagi menjadi 3 cluster.

The screenshot shows the KNIME Analytics Platform interface. The workflow consists of the following nodes: Excel Reader, Missing Value, Normalizer, and k-Means. A data table is displayed with the following columns: #, RowID, Provinsi, 2018, 2019, 2020, and Cluster. The table contains 34 rows of data, representing various provinces in Indonesia and their corresponding values for the years 2018, 2019, and 2020, grouped into 3 clusters.



#	RowID	Provinsi	2018	2019	2020	Cluster
1	Row0	ACEH	0.5	0.553	0.553	cluster_0
2	Row1	SUMATERA UTARA	0.553	0.553	0.553	cluster_0
3	Row2	SUMATERA BARAT	0.421	0.447	0.447	cluster_0
4	Row3	RIAU	0.263	0.263	0.263	cluster_1
5	Row4	JAMBI	0.132	0.184	0.184	cluster_1
6	Row5	SUMATERA SELATAN	0.211	0.211	0.237	cluster_1
7	Row6	BENGKULU	0.079	0.079	0.105	cluster_2
8	Row7	LAMPUNG	0.263	0.289	0.289	cluster_1
9	Row8	KEP. BANGKA & LAMPUNG	0.132	0.158	0.158	cluster_1
10	Row9	KEP. RIAU	0.079	0.079	0.079	cluster_2
11	Row10	DKI JAKARTA	0.158	0.158	0.158	cluster_1
12	Row11	JAWA BARAT	0.605	0.605	0.658	cluster_0
13	Row12	JAWA TENGAH	0.789	0.868	0.868	cluster_0
14	Row13	DI YOGYAKARTA	0.079	0.105	0.105	cluster_2
15	Row14	JAWA TIMUR	1	1	1	cluster_0
16	Row15	BANTEN	0.158	0.158	0.158	cluster_1
17	Row16	BALI	0.237	0.237	0.237	cluster_1
18	Row17	NUSA TENGGARA	0.079	0.079	0.079	cluster_2

Tambahkan node Cluster Assigner, node ini berfungsi untuk menambahkan label cluster dengan cara menambahkan kolom baru ke dataset yang berisi label cluster untuk setiap data point berdasarkan hasil clustering. Selain itu, node ini juga menggabungkan data input dengan informasi cluster, sehingga menghasilkan dataset yang lebih informatif. Dengan label cluster yang ditambahkan, node ini memudahkan analisis lebih lanjut, seperti visualisasi dan analisis karakteristik masing-masing cluster. Selain itu, Cluster Assigner mempersiapkan dataset agar informasi cluster dapat digunakan dalam model prediktif lainnya. Secara keseluruhan, node ini sangat penting untuk menganalisis dan memahami hasil clustering.




#	RowID	Provinsi String	2018 Number (double)	2019 Number (double)	2020 Number (double)	Cluster String	Cluster (#1) String
1	Row0	ACEH	0.5	0.553	0.553	cluster_0	cluster_0
2	Row1	SUMATERA UTARA	0.553	0.553	0.553	cluster_0	cluster_0
3	Row2	SUMATERA BARAT	0.421	0.447	0.447	cluster_0	cluster_0
4	Row3	RIAU	0.263	0.263	0.263	cluster_1	cluster_1
5	Row4	JAMBI	0.132	0.184	0.184	cluster_1	cluster_1
6	Row5	SUMATERA SELATAN	0.211	0.211	0.237	cluster_1	cluster_1
7	Row6	BENGKULU	0.079	0.079	0.105	cluster_2	cluster_2
8	Row7	LAMPUNG	0.263	0.289	0.289	cluster_1	cluster_1
9	Row8	KEP. BANGKA BELITUNG	0.132	0.158	0.158	cluster_1	cluster_1
10	Row9	KEP. RIAU	0.079	0.079	0.079	cluster_2	cluster_2
11	Row...	DKI JAKARTA	0.158	0.158	0.158	cluster_1	cluster_1
12	Row...	JAWA BARAT	0.605	0.605	0.658	cluster_0	cluster_0
13	Row...	JAWA TENGAH	0.789	0.868	0.868	cluster_0	cluster_0
14	Row...	DI YOGYAKARTA	0.079	0.105	0.105	cluster_2	cluster_2
15	Row...	JAWA TIMUR	1	1	1	cluster_0	cluster_0
16	Row...	BANTEN	0.158	0.158	0.158	cluster_1	cluster_1
17	Row...	BALI	0.237	0.237	0.237	cluster_1	cluster_1
18	Row...	NUSA TENGGARA BARAT	0.079	0.079	0.079	cluster_2	cluster_2
19	Row...	NUSA TENGGARA TIMUR	0	0	0.079	cluster_2	cluster_2
20	Row...	KALIMANTAN BARAT	0.079	0.079	0.105	cluster_2	cluster_2
21	Row...	KALIMANTAN TENGAH	0.237	0.263	0.289	cluster_1	cluster_1
22	Row...	KALIMANTAN SELATAN	0.184	0.184	0.184	cluster_1	cluster_1
23	Row...	KALIMANTAN TIMUR	0.079	0.079	0.079	cluster_2	cluster_2
24	Row...	KALIMANTAN UTARA	0.026	0.026	0.079	cluster_2	cluster_2
25	Row...	SULAWESI UTARA	0.158	0.158	0.211	cluster_1	cluster_1
26	Row...	SULAWESI TENGAH	0.105	0.122	0.158	cluster_1	cluster_1

Kemudian tambahkan ketiga node berikut untuk menampilkan hasil dalam bentuk visualiasi



Lalu kita juga dapat menyimpan table yang sudah melalui proses clustering ke format excel dengan menambahkan node Excel Writer.



Tentukan di folder mana file akan disimpan, namun bisa juga dengan melakukan rewrite pada file excel yang sudah ada, namun disarankan tidak menggunakan file yang digunakan dalam proses K-Means.

Dialog - 4:9 - Excel Writer

File

Settings

Encryption

Flow Variables

Job Manager Selection

File format & output location

Excel format

XLSX

Write to

Local File System

File

C:\Users\RAMA\Downloads\malaria_kmeans.xlsx

Browse...

Write options

☐ Create missing folders

If exists: ☐ overwrite ☐ append ☒ fail

Sheets

1. sheet name

default_1

If sheet exists

☐ overwrite ☐ append ☒ fail

Names and IDs

☐ Write row key

☒ Write column headers

☒ Don't write column headers if sheet exists

Missing value handling

☐ Replace missing values by

Formulas

☐ Evaluate formulas (leave unchecked if uncertain; see node description for details)

Layout

☐ Autosize columns

☒ Portrait ☐ Landscape

A4 - 210x297 mm

☐ Open file after execution

OK

Apply

Cancel

The screenshot displays an Excel spreadsheet titled 'malaria_kmeans'. The data is organized into columns for years (2018, 2019, 2020) and clusters (cluster_0, cluster_1, cluster_2). The rows list various Indonesian provinces and districts. The data values are small decimal numbers, likely representing probabilities or weights assigned to each cluster for each region. For example, for Aceh, the values are 0.002631579 for 2018, 0.052631579 for 2019, and 0.04798421 for 2020, all assigned to cluster_0. The spreadsheet also shows a ribbon with various tabs like File, Home, Insert, Page Layout, Formulas, Data, Review, View, Automate, and Help.

	2018	2019	2020	Cluster	Cluster (k1)
ACEH	0.002631579	0.052631579	0.04798421	cluster_0	cluster_0
SUMATERA UTARA	0.052631579	0.052631579	0.04798421	cluster_0	cluster_0
SUMATERA BARAT	0.421920632	0.44798421	0.44798421	cluster_1	cluster_1
RIAU	0.263157895	0.263157895	0.263157895	cluster_1	cluster_1
JAMBI	0.131578947	0.184210526	0.184210526	cluster_1	cluster_1
SUMATERA SELATAN	0.210526316	0.210526316	0.268421053	cluster_1	cluster_1
BENGKULU	0.078947368	0.078947368	0.102631579	cluster_2	cluster_2
LAMPUNG	0.263157895	0.268473684	0.268473684	cluster_1	cluster_1
KEP. BANGKA BELITUNG	0.131578947	0.137894737	0.157894737	cluster_1	cluster_1
KEP. RIAU	0.078947368	0.078947368	0.078947368	cluster_1	cluster_1
DKI JAKARTA	0.137894737	0.137894737	0.137894737	cluster_1	cluster_1
JAWA BARAT	0.05263158	0.05263158	0.057894737	cluster_0	cluster_0
JAWA TENGAH	0.789473684	0.868421053	0.868421053	cluster_0	cluster_0
DI YODHYAKARTA	0.078947368	0.105263158	0.105263158	cluster_2	cluster_2
JAWA TIMUR	1	1	1	cluster_0	cluster_0
BANTEN	0.157894737	0.137894737	0.157894737	cluster_2	cluster_1
BALI	0.236842105	0.236842105	0.236842105	cluster_1	cluster_1
NUSA TENGGARA BARAT	0.078947368	0.078947368	0.078947368	cluster_2	cluster_2
NUSA TENGGARA TIMUR	0	0	0.078947368	cluster_2	cluster_2
KALIMANTAN BARAT	0.078947368	0.078947368	0.105263158	cluster_2	cluster_2
KALIMANTAN TENGAH	0.26842105	0.263157895	0.268473684	cluster_1	cluster_1
KALIMANTAN SELATAN	0.184210526	0.184210526	0.184210526	cluster_1	cluster_1
KALIMANTAN TIMUR	0.078947368	0.078947368	0.078947368	cluster_2	cluster_2
KALIMANTAN UTARA	0.052631579	0.052631579	0.078947368	cluster_2	cluster_2
SULAWESI UTARA	0.137894737	0.137894737	0.105263158	cluster_1	cluster_1
SULAWESI TENGAH	0.105263158	0.131578947	0.157894737	cluster_1	cluster_1
SULAWESI SELATAN	0	0.052631579	0.052631579	cluster_1	cluster_0
SULAWESI TENGGARA	0.236842105	0.236842105	0.268473684	cluster_1	cluster_1
GORONTALO	0.052631579	0.052631579	0.052631579	cluster_2	cluster_2
SULAWESI BARAT	0.078947368	0.131578947	0.131578947	cluster_2	cluster_2
MALUKU	0	0	0	cluster_2	cluster_2
MALUKU UTARA	0	0	0.052631579	cluster_2	cluster_2
PAPUA BARAT	0	0	0	cluster_2	cluster_2
PAPUA	0	0	0	cluster_2	cluster_2